Компиляция статической маршрутизации с нелинейностью до агрегации

Цель исследования — ускорить вывод обученного слоя с индивидуальными порогами нейронов и измерить изменение качества и памяти.

Такшин А. И.
Научный руководитель — Синильщиков И. В.

Общие статистики для индивидуальных порогов

Слой усредняет отклики BiReLU по обученным вероятностям маршрутов. При выводе компилятор хранит явные маршруты и остаточную массу групп.

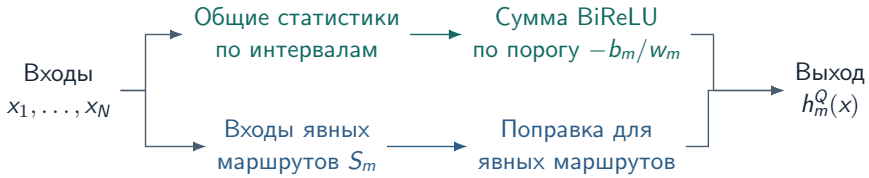

$2{,}81\times$
быстрее точного кеша

$10{,}3\times$
меньше явной памяти

$-0{,}35$
п.п. точности на тесте

База сравнения — исходная маршрутизирующая сеть с точным кешем. CIFAR-10, точность по трём запускам. Замеры Apple M3 Pro CPU, FP32, batch 1, seed 0.

Статические маршруты и агрегация хвоста

Близкая работа	Используемая идея
Synthesizer, 2021	Статические факторизованные логиты
KAN, 2025 и TruKAN, 2026	Одномерные функции перед суммой
SparQ, 2024 и OpenAttention, 2026	Агрегация отброшенной части внимания

Вклад работы

Компиляция сжатого статического слоя. Нейроны с разными порогами BiReLU читают одни и те же статистики группы.

Слой средних и критерии сравнения

Обучаемый слой

$$h_m^P(x) = \sum_i p_{mi}\, g(w_m x_i + b_m)$$

$$g(u) = \tfrac{1}{2}u + \tfrac{3}{2}\max(u, 0)$$

Пара w_m, b_m общая для всех входов нейрона m.
Строка P задаёт вероятности входных координат.

Критерии

Точность и кросс-энтропия

Память массивов и рабочих буферов

Задержка полного вывода

Чекпойнты выбираются по валидационной точности. Коэффициенты сжатия подгоняются на обучающем разбиении. Тест служит для итоговой оценки.

Как ускоряется вывод на одном патче

Интенсивности

20	40	70
80	100	130
160	220	230

Условный патч 3×3

Вероятности нейрона

0,04	0,07	0,28
0,05	0,10	0,03
0,09	0,22	0,12

Синим — явные маршруты

После сжатия

c	c	0,28
c	c	c
c	0,22	c

Семь вероятностей заменяем на $c = 0{,}50/7$

Один раз на патч считаем число пикселей и сумму по интервалам.

Интервал интенсивностей	$x \le 90$	$90 < x \le 170$	$x > 170$
Число и сумма	$4,\ 210$	$3,\ 390$	$2,\ 450$

При $w > 0$ нейрон с порогом 90 берёт две правые колонки, с порогом 170 — одну. Для каждого нейрона вычисляем BiReLU по отдельности только на его явных маршрутах.

Сжатие вероятностей и точное вычисление

Офлайн

Сохраняем top-K маршрутов. Остаточную массу равномерно распределяем по отброшенным входам каждой группы.

На каждом объекте

Считаем число и сумму значений по обе стороны порога. Добавляем поправку для явных маршрутов.

$$\sum_{i \in G} g(w_m x_i + b_m) = \tfrac{1}{2}(w_m s + b_m n) + \tfrac{3}{2}(w_m s_+ + b_m n_+).$$

n, s — число и сумма значений группы. n_+, s_+ — те же статистики для $w_m x_i + b_m > 0$.

Исполнитель точно вычисляет сжатую модель Q с учётом округления.
Потерю при замене исходных вероятностей P на Q измеряем отдельно.

Полные модели близки по точности на CIFAR-10

Набор	Скрытых слоёв	Dense	Средние до суммы
MNIST	2	98,00	95,49
MNIST	4	98,28	95,99
CIFAR-10	3	50,60	50,31
CIFAR-10	4	50,58	51,67

Точность на тесте, %. Чекпойнты выбраны по валидации, один seed. Бюджеты 500 эпох на MNIST и 2000 на CIFAR-10.

При ранге 8 оба порядка BiReLU опередили Factor Dense на CIFAR

Набор	Эпох	Factor Dense	До суммы	После суммы
CIFAR-10	800	44,60	**49,12**	48,46
Fashion-MNIST	500	85,92	85,60	**85,94**
CIFAR-100	400	17,73	**20,63**	20,07

Точность на тесте, %, среднее по трём запускам. В каждой строке близкое число параметров. Ранг относится к весам Dense и к логитам маршрутизации соответственно.

На CIFAR-10 к 1200 эпохам полный Dense дал 50,81%, компактная модель до суммы — 50,58%. Число параметров уменьшилось с 570 570 до 36 426.

Потеря точности при сжатии — до 0,35 п.п.

Набор	Точный кеш	Сжатая сеть	Разница, п.п.
CIFAR-10	50,58%	50,23%	$-0{,}35$
Fashion-MNIST	85,60%	85,46%	$-0{,}14$
CIFAR-100	20,63%	20,36%	$-0{,}27$

Точность на тесте, три запуска. Бюджет $K = (64, 32, 64, 32)$ выбран на CIFAR-10. Подгонка коэффициентов и линейной шапки использует 1536 обучающих изображений каждого набора.

Контроль нелинейности на Fashion-MNIST

При одинаковых маршрутах и массах хвоста точная сумма BiReLU дала 85,79% на валидации, BiReLU от среднего хвоста — 83,43%.

На CPU сжатая сеть быстрее собственного точного кеша

Исполнитель FP32	Batch 1, мкс	Batch 128, мс	Память, байт
Точный кеш маршрутов	59,92	6,435	≈2 288 760
Сжатый, сортировка	24,72	2,730	209 172
Сжатый, интервалы порогов	**21,29**	2,277	**221 460**
Dense, Accelerate	13,78	0,198	2 283 600

CIFAR-10, seed 0, Apple M3 Pro CPU. Медиана за пакет. Память включает хранимые массивы и явные рабочие буферы для batch 1.

Сжатый исполнитель сохранил все 10 000 предсказаний *сжатой* формулы на тесте для seed 0.

Компиляция полезна для фиксированной маршрутизирующей сети

Сравнение	Вывод
С точным кешем	В 2,81 раза быстрее и в 10,3 раза меньше явной памяти при batch 1.
На трёх наборах	Потеря тестовой точности после сжатия от 0,14 до 0,35 п.п.
С Dense	Оптимизированный FP32 Dense быстрее. При близком объёме хранения Factor Dense INT8 точнее на CIFAR-10 и CIFAR-100.

Дальнейшая проверка

Повторить замеры на другом CPU и проверить слои с несколькими порогами.