Компиляция статической маршрутизации с нелинейностью до агрегации

Цель исследования — ускорить вывод обученного слоя с индивидуальными порогами нейронов и измерить изменение качества и памяти.

Общие статистики для индивидуальных порогов

Слой усредняет отклики BiReLU по обученным вероятностям маршрутов. При выводе компилятор хранит явные маршруты и остаточную массу групп.

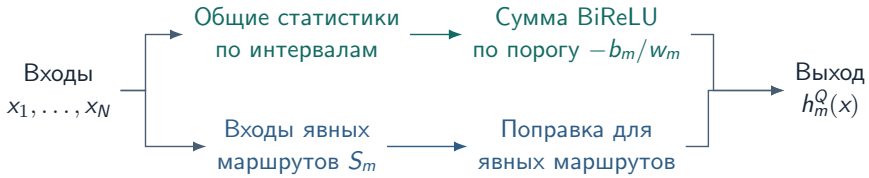

$2{,}81\times$
быстрее точного кеша

$10{,}3\times$
меньше явной памяти

$-0{,}35$
п.п. точности на тесте

База сравнения — исходная маршрутизирующая сеть с точным кешем. CIFAR-10, точность по трём запускам. Замеры Apple M3 Pro CPU, FP32, batch 1, seed 0.

Статические маршруты и агрегация хвоста

Близкая работа	Используемая идея
Synthesizer, 2021	Статические факторизованные логиты
KAN, 2025 и TruKAN, 2026	Одномерные функции перед суммой
SparQ, 2024 и OpenAttention, 2026	Агрегация отброшенной части внимания

Вклад работы

Компиляция сжатого статического слоя. Нейроны с разными порогами BiReLU читают одни и те же статистики группы.

Слой средних и критерии сравнения

Обучаемый слой

$$h_m^P(x) = \sum_i p_{mi}\, g(w_m x_i + b_m)$$

$$g(u) = \tfrac{1}{2}u + \tfrac{3}{2}\max(u, 0)$$

Пара w_m, b_m общая для всех входов нейрона m.
Строка P задаёт вероятности входных координат.

Критерии

Точность и кросс-энтропия

Память массивов и рабочих буферов

Задержка полного вывода

Чекпойнты выбираются по валидационной точности. Коэффициенты сжатия подгоняются на обучающем разбиении. Тест служит для итоговой оценки.

Сжатие вероятностей и точное вычисление

Офлайн

Сохраняем top-K маршрутов. Остаточную массу равномерно распределяем по отброшенным входам каждой группы.

На каждом объекте

Считаем число и сумму значений по обе стороны порога. Добавляем поправку для явных маршрутов.

$$\sum_{i \in G} g(w_m x_i + b_m) = \tfrac{1}{2}(w_m s + b_m n) + \tfrac{3}{2}(w_m s_+ + b_m n_+).$$

n, s — число и сумма значений группы. n_+, s_+ — те же статистики для $w_m x_i + b_m > 0$.

Исполнитель точно вычисляет сжатую модель Q с учётом округления.
Потерю при замене исходных вероятностей P на Q измеряем отдельно.

Полные модели близки по точности на CIFAR-10

Набор	Скрытых слоёв	Dense	Средние до суммы
MNIST	2	98,00	95,49
MNIST	4	98,28	95,99
CIFAR-10	3	50,60	50,31
CIFAR-10	4	50,58	51,67

Точность на тесте, %. Чекпойнты выбраны по валидации, один seed. Бюджеты 500 эпох на MNIST и 2000 на CIFAR-10.

При ранге 8 оба порядка BiReLU опередили Factor Dense на CIFAR

Набор	Эпох	Factor Dense	До суммы	После суммы
CIFAR-10	800	44,60	**49,12**	48,46
Fashion-MNIST	500	85,92	85,60	**85,94**
CIFAR-100	400	17,73	**20,63**	20,07

Точность на тесте, %, среднее по трём запускам. В каждой строке близкое число параметров. Ранг относится к весам Dense и к логитам маршрутизации соответственно.

На CIFAR-10 к 1200 эпохам полный Dense дал 50,81%, компактная модель до суммы — 50,58%. Число параметров уменьшилось с 570 570 до 36 426.

Потеря точности при сжатии — до 0,35 п.п.

Набор	Точный кеш	Сжатая сеть	Разница, п.п.
CIFAR-10	50,58%	50,23%	$-0{,}35$
Fashion-MNIST	85,60%	85,46%	$-0{,}14$
CIFAR-100	20,63%	20,36%	$-0{,}27$

Точность на тесте, три запуска. Бюджет $K = (64, 32, 64, 32)$ выбран на CIFAR-10. Подгонка коэффициентов и линейной шапки использует 1536 обучающих изображений каждого набора.

Контроль нелинейности на Fashion-MNIST

При одинаковых маршрутах и массах хвоста точная сумма BiReLU дала 85,79% на валидации, BiReLU от среднего хвоста — 83,43%.

На CPU сжатая сеть быстрее собственного точного кеша

Исполнитель FP32	Batch 1, мкс	Batch 128, мс	Память, байт
Точный кеш маршрутов	59,92	6,435	≈2 288 760
Сжатый, сортировка	24,72	2,730	209 172
Сжатый, интервалы порогов	**21,29**	2,277	**221 460**
Dense, Accelerate	13,78	0,198	2 283 600

CIFAR-10, seed 0, Apple M3 Pro CPU. Медиана за пакет. Память включает хранимые массивы и явные рабочие буферы для batch 1.

Сжатый исполнитель сохранил все 10 000 предсказаний *сжатой* формулы на тесте для seed 0.

Компиляция полезна для фиксированной маршрутизирующей сети

Сравнение	Вывод
С точным кешем	В 2,81 раза быстрее и в 10,3 раза меньше явной памяти при batch 1.
На трёх наборах	Потеря тестовой точности после сжатия от 0,14 до 0,35 п.п.
С Dense	Оптимизированный FP32 Dense быстрее. При близком объёме хранения Factor Dense INT8 точнее на CIFAR-10 и CIFAR-100.

Дальнейшая проверка

Повторить замеры на другом CPU и проверить слои с несколькими порогами.